



서울 PM 수요 예측 & 재배치 모델

기업맞춤형 AI-X 융복합 인재 양성 교육

1 조 | 조명환, 박선우, 정종혁, 김도현 | 2025.07.10

목차

01 프로젝트 개요

- 문제 배경
- 웹서비스 시연

02 데이터 수집 및 분석

- 데이터 수집 개요
- 데이터 분석 인사이트
- 시계열 특성

03 모델개발과정

- M1 모델
- M2 모델

04 발전계획

- 향후추진계획
- 참고문헌
- Q&A

목차

01 프로젝트 개요

- 문제 배경
- 웹서비스 시연

02 데이터 수집 및 분석

- 데이터 수집 개요
- 데이터 분석 인사이트
- 시계열 특성

03 모델개발과정

- M1 모델
- M2 모델

04 발전계획

- 향후추진계획
- 참고문헌
- Q&A

프로젝트 일정조율 및 과정

활동내용	07월 10일	07월 11일	07월 12일	07월 13일	07월 14일	07월 15일	07월 16일	07월 17일	07월 18일	07월 19일	07월 20일	07월 21일	07월 22일	07월 23일
기획 및 설계														
주제 선정과 목표 설정	계획	수행												
주제에 대한 feature 확인		계획	수행											
데이터 확보 계획 수립			계획	수행										
데이터 수집과 정리														
서울시 열린데이터광장 데이터				계획	수행									
기상청 데이터				계획	수행									
공공데이터포털 데이터					계획	수행								
통계청 데이터					계획	수행								
수집데이터 DB 적재					계획	수행								
연구 모형 및 조사 설계														
데이터 특성 확인 분석					계획	수행								
데이터 전처리					계획	수행								
공공자전거 대여량 예측 모형						계획	수행							
민간PM 수요 예측 모형							계획	수행						
완성 모형 서비스화														
완성 모형 함수화											계획	수행		
Flask를 통한 Prototype 구현											계획	수행		
Prototype 구동 점검 및 수정												계획	수행	
PR 자료 준비												계획	수행	
테스트 및 수정 : 향후 진행														

계획 수행

7월 10일~13일
프로젝트 기획 및 설계



7월 13일~15일
데이터 수집과 정리




7월 15일~20일
연구 모형 및 조사 설계



7월 20일~23일
완성 모형 서비스화

워크플로우(개발과정)



퍼스널 모빌리티



퍼스널 모빌리티(Personal Mobility) 란?

- 자전거, 전동킥보드, 전기자전거, 전동휠 등 1인 이동수단을 지칭
- 교통혼잡해결, 친환경성, 라스트마일(Last-Mile)해결 등으로 세계적으로 각광받는 추세

문제 배경



그 많은 새싹따릉이는 다 어디로 간 것일까..."물량 부족 아닌 배치 효율성 문제"

김하나 기자 (hanakim@dailian.co.kr)
입력 2023.11.25 06:01 수정 2023.11.25 06:01

🔊 🖨️ 🔍 📄

서울시 청소년 공공자전거 새싹따릉이 5000대, 전체 따릉이 9% 육박...대여도 2년 만에 16배 증가
새싹따릉이 월 평균 한 대당 이용률은 저조...하루 일반따릉이 1대가 4회, 새싹따릉이 1대가 1회 꼴
새싹따릉이 배치 물량 부족하기 보다는...실제 수요 많은 지역에 효율적 배치하지 못하고 있는 것
시 "새싹따릉이, 모든 따릉이배치소마다 배치하지 못하고 있어...접근성·효율적 재배치 위해 노력중"



PM 수요-공급 불균형에 따라 PM 운용에 대한 실효성 문제가 발생하고 있음!

PM 수요 불균형 현상

- 서울시 공공자전거(따릉이) 대여소별 수요 편차 심화
- 출퇴근 시간대 특정 지역 PM 부족 현상 발생
- 민간 PM 서비스(킵보드 등)도 유사한 불균형 패턴 보임
- 비효율적 재배치로 인한 운영 비용 증가

실태 분석

- 뉴스 및 언론 보도를 통한 문제 인식
- 공공데이터 분석 결과 지역별, 시간대별 수요 편차 확인
- 유동인구 데이터와 PM 대여량 간 상관관계 발견
- 기상 조건에 따른 수요 변동 가능성 확인

프로젝트 개요

수요 예측 모델 개발

- 시간적 요소를 고려한 수요 예측
 - * 시간대, 요일, 계절
- 공간적 요소에 따른 수요 패턴 분석
 - * 행정구역, 주변 시설
- 공공자전거와 민간 PM 서비스의 수요 특성분석
- 딥러닝 기반 시계열 예측 모델(DNN) 적용
- 예측된 수요에 기반한 최적 재배치 경로 설계



AI 기술을 활용한 효율적 재배치 전략 수립

- 운영 비용 최소화와 사용자 편의성 극대화
- 공공자전거와 민간 PM을 고려한 맞춤형 전략
- 재배치 작업의 효율성 측정을 위한 평가 지표
- 웹 기반 관리 시스템을 통한 재배치 모니터링

웹 서비스 소개: 최초화면


The screenshot shows the FlowCast website interface. At the top left is the FlowCast logo and tagline "FlowCast: We Forecast the Urban Flow". In the center is a large FlowCast logo with the tagline "We forecast the urban flow." Below this is the title "서울의 흐름을 예측하다, FlowCast" and a subtitle "행정구별 PM 수요를 데이터로 분석합니다.".

The main content area features three input fields and three buttons, each highlighted with a red box and a numbered annotation:


- Annotation 1:** A red box labeled "① 행정구 선택창" (Administrative District Selection Window) points to a dropdown menu labeled "행정구를 선택하세요" (Select administrative district).
- Annotation 2:** A red box labeled "② 일자 선택창" (Date Selection Window) points to a date input field showing "2025-07-17".
- Annotation 3:** A red box labeled "③ 실행" (Execute) points to three buttons: "공공자전거 수요 예측" (Public Bicycle Demand Prediction), "PM 수요 예측" (PM Demand Prediction), and "오늘의 대표역 5곳 결과" (Today's Top 5 Representative Stations Results).

At the bottom left, there is a footer with the text "© FlowCast | www.devna01111@gmail.com | copyright © FlowCast co.,Ltd All rights reserved".


웹 서비스 소개: 출력화면




웹 서비스 소개: 출력화면




웹 서비스 소개: 출력화면



웹 서비스 시연: 영상



PM 수요 예측 및 재배치 모델의 기대 효과



자원 최적화

- 수요 예측을 통한 PM 배치 최적화
- 행정구별 필요 수량 정확한 산정
 - 과잉/과소 공급 문제 해결
 - 유헴 자원 최소화
- 효율적인 재배치 전략 수립



비용 절감

- 불필요한 재배치 작업 감소
 - 유지보수 비용 절감
 - 인력 운영 효율화
 - 장비 수명 연장
- 에너지 소비 최소화



사용자 편의성

- 필요시점, 필요장소에서 PM 이용
 - 대기 시간 감소
 - 예약 시스템 연계 가능성
 - 사용자 만족도 향상
 - 재이용률 증가



환경적 가치


- 불필요한 차량 이동 감소
 - 탄소 배출량 절감
 - 친환경 교통수단 활성화
 - 도시 교통 혼잡 완화
- 지속가능한 모빌리티 생태계 구축

기술 응용 분야



PM 공유 서비스 사업

- 재배치 자동화: 수요 과소/과잉 지역을 실시간 예측해 장비를 자동으로 옮기도록 설정
- 운영 효율성: 적재적소에 PM 배치
→ 과잉 배치로 인한 비용 절감
- 유휴 장비 최소화: 회전율 증가
- 고객 만족도 향상: 필요한 시간과 장소에 PM이 있음 → 고객 이탈률 감소



공공정책 및 도시계획

- PM 허브 입지 선정 및 기반시설 구축
- 자치구 단위 수요 분석
→ 예산/정책 우선순위 결정
- 공공자전거 및 민간PM 통합 계획 수립
- PM 이용률 증가에 따른 탄소배출 감소 효과
- 지속가능한 교통 모델로의 전환 전략 수립



PM 기반 배달/운송 서비스 고도화

- 배달기사용 PM 장비 수요 예측
→ 출발지에 사전 배치
- 날씨+생활인구 기반 수요예측
→ 배달 경로 최적화
- 혼잡시간대 회전율 극대화 전략 수립

목차

01 프로젝트 개요

- 문제 배경
- 웹서비스 시연

02 데이터 수집 및 분석

- 데이터 수집 개요
- 데이터 분석 인사이트
- 시계열 특성

03 모델개발과정

- M1 모델
- M2 모델

04 발전계획

- 향후추진계획
- 참고문헌
- Q&A

데이터 분석 인사이트



PM 수요는 시간(출퇴근 시간대), 공간(핫스팟), 기상조건(기온, 강수), 인구특성(연령대)과 높은 상관관계를 보일것으로 판단 후 데이터 수집

인구 상관성

- 생활인구와 높은 상관관계
- 20-30대 밀집 지역 수요 증가
- 관광객 영향 높음

공간적 특성

- 강남, 홍대 등 핫스팟 존재
- 대학가 주변 높은 수요

- 기온 15-25도에서 최적 이용률
- 강수 시 급감
- 미세먼지 농도 영향
- 계절 전환기 변동 큼

시간적 특성

- 출퇴근 시간대 수요 급증
- 주말과 평일 패턴 상이
- 계절별 변동성 확인

데이터 수집 (인구)

- 정확한 수요 예측: 시간·공간별 유동인구·생활인구 반영으로 피크 타임 수요 예측
- 효율적 자원 배치: 인구 밀집 지역엔 충분, 저밀도 지역엔 최소 배치로 운영 비용 절감
- 결과 해석 지원: “왜 이 시간·구역에서 이용량이 늘었는지” 설명

유동인구

행정인구

생활인구

공공데이터




일반행정

활용사례 등록 URL 복사 목록 이동

스마트서울 도시데이터 센서(S-DoT) 유동인구 측정 정보
센서수량 및 설치장소 : 서울 전역 100대(전통시장, 주요거리, 공원, 공공시설)
측정정보 : S-DoT에서 측정된 유동인구(10분단위 데이터)
유의사항
- S-DoT 유동인구 데이터는 “열린데이터광장”을 통해서만 제공하며 관리부서에서는 별도로 제공하지 않습니다.

[전체 설명보기](#)



자치구	행정동	방문자수	등록일
Jungnang-gu	Muk2(i)-dong	149	2025-06-23 00:08:05
Gangbuk-gu	Mia-dong	190	2025-06-23 00:08:05
Gangbuk-gu	Mia-dong	190	2025-06-23 00:08:06
Guro-gu	Gocheok2(i)-dong	166	2025-06-23 00:08:06
Jongno-gu	Gahoe-dong	0	2025-06-23 00:08:06
...	...	...	...
Seongdong-gu	Seongsu1ga1(il)-dong	1	2025-06-29 23:58:04
Dongjak-gu	Sang-do1(il)-dong	264	2025-06-29 23:58:05
Dongjak-gu	Sadang2(i)-dong	187	2025-06-29 23:58:05
Dongjak-gu	Sang-do1(il)-dong	165	2025-06-29 23:58:05
Dongjak-gu	Sang-do4(sa)-dong	233	2025-06-29 23:58:05

** 유동인구 : 실시간 위치 기반, 장소, 중심 / 범주형 / 시간대에 대한 정확한 정보 부족

2025년 이전 자료 부재

데이터 수집 (인구)

- 정확한 수요 예측: 시간·공간별 유동인구·생활인구 반영으로 피크 타임 수요 예측
- 효율적 자원 배치: 인구 밀집 지역엔 충분, 저밀도 지역엔 최소 배치로 운영 비용 절감
- 결과 해석 지원: “왜 이 시간·구역에서 이용량이 늘었는지” 설명

유동인구

행정인구

생활인구

공공데이터



일반행정

활용사례 등록


URL 복사

목록 이동

인구관

행정동 단위 서울 생활인구(내국인)

서울시가 보유한 공공데이터와 통신폰데이터로 측정한 특정시점에 서울의 특정 지역에 존재하는 모든인구수 정보※ Sheet, Open API는 최근 2개월 데이터만 제공합니다.



기준 일 ID	시간대구 분	행정동코드	총생활인구 수
0	11170690	13016.4691	504.7423
0	11260660	12465.4868	402.3057
0	11620735	27735.1490	357.5485
0	11290640	14738.4304	273.6058
0	11215830	24319.6994	969.6121
...	...	...	...
23	11260520	21684.5150	810.4878
23	11260540	16575.0765	555.9794
23	11650600	17385.1708	925.4452
23	11680600	25429.5099	1267.1376
23	11260550	12535.5624	367.0228

ws × 32 columns

행정구에 등록된
생활인구만 확인가능

**행정인구 : 주민등록 기준 공식 인구 / 정적인 데이터 / 실제 체류 인구 반영 어려움

데이터 수집 (인구)

- 정확한 수요 예측: 시간·공간별 유동인구·생활인구 반영으로 피크 타임 수요 예측
- 효율적 자원 배치: 인구 밀집 지역엔 충분, 저밀도 지역엔 최소 배치로 운영 비용 절감
- 결과 해석 지원: “왜 이 시간·구역에서 이용량이 늘었는지” 설명

유동인구

행정인구

생활인구

공공데이터




활용사례 등록 URL 복사 목록 이동

자치구단위 서울생활인구 일별 집계표

서울 생활인구 일별 집계 정보입니다.
집계구, 행정동별, 성별, 연령대별 통계를 제공합니다.

일반행정



	총생활인구수	일시	행정구
0	14473.8890	2021-01-01 00:00:00	종로구
1	13299.5313	2021-01-01 00:00:00	종로구
2	15518.3772	2021-01-01 00:00:00	종로구
3	5108.9481	2021-01-01 00:00:00	종로구
4	7907.7246	2021-01-01 00:00:00	종로구
...	...	...	...
3714235	21687.6749	2021-12-31 23:00:00	양천구
3714236	56597.5455	2021-12-31 23:00:00	강동구
3714237	33165.7067	2021-12-31 23:00:00	강서구
3714238	36194.0265	2021-12-31 23:00:00	광진구
3714239	22589.9182	2021-12-31 23:00:00	영등포구

3714240 rows × 3 columns

- 시간대별 인구 확인 가능 → 피크타임 수요 예측 적합
- 공간 기반 분석 가능 → 자치구·동 단위 수요 분석
- 연속 수치형 데이터 → 머신러닝 모델 학습 용이
- 실제 생활 반영 반영 → 행정인구보다 현실성 높음

데이터 수집 (인프라)

- 접근성 최적화 : 도로·전용자전거도로 연결성 높은 지역에 PM 집중 배치
- 안전성 고려 : 인프라 밀집 구역일수록 이용률 증가 → 사고 리스크 감소
- 공간 수요 식별 : 도로 연결성 지표로 고수요·저수요 지역 명확히 구분

대여정보

자전거 도로




[교통]

서울시 공공자전거 실시간 대여정보 Update

서울특별시 공공자전거 실시간 대여정보입니다. 대여소별 실시간 자전거 대여가능 건수, 거치율, 대여...
수정일자: 2025-07-09 제공기관: 서울특별시 제공부서: 교통실 교통운영관 보행자전거과

OpenAPI

데이터



대여일자		대여소번호		대여소	대여구분코드	성별	연령대	이용건수	운동량	탄소량	이동거리(M)	이용시간(분)
0	2024-12-01	737		737. 장수공원	정기권	NaN	~10대	1	20.97	0.18	790.32	14
1	2024-12-01	1153	1153. 발산역 1번, 9번 인근 대여소	정기권	NaN	NaN	~10대	1	NaN	NaN	1143.00	56
2	2024-12-01	1155	1155. 기쁜우리복지관	정기권	NaN	NaN	~10대	1	12.49	0.15	643.66	4
3	2024-12-01	1442	1442. 중랑구청 중화동 별관 앞	정기권	NaN	NaN	~10대	3	217.31	1.43	6152.66	42
4	2024-12-01	1160	1160. 양천향교역 7번출구앞	정기권	NaN	NaN	~10대	1	28.23	0.30	1296.07	8
...	...	...	...	...	...	...	...	...	...	...	...	...
1410911	2024-12-31	3500	3500. 군자역2번출구	정기권	M	기타	기타	1	60.00	0.54	2331.01	27
1410912	2024-12-31	3504	3504. 원일교회	정기권	M	기타	기타	1	37.74	0.34	1466.26	70
1410913	2024-12-31	502	502. 자양(독섬한강공원)역 1번출구 앞	정기권	M	기타	기타	1	155.05	1.40	6023.60	74
1410914	2024-12-31	723	723. SBS방송국	정기권	M	기타	기타	1	30.51	0.27	1185.26	10
1410915	2024-12-31	726	726. 목동3단지 시내버스정류장	정기권	M	기타	기타	1	26.59	0.20	872.14	6

1410916 rows × 11 columns

데이터 수집 (인프라)

- 접근성 최적화 : 도로·전용자전거도로 연결성 높은 지역에 PM 집중 배치
- 안전성 고려 : 인프라 밀집 구역일수록 이용률 증가 → 사고 리스크 감소
- 공간 수요 식별 : 도로 연결성 지표로 고수요·저수요 지역 명확히 구분

대여정보

자전거 도로



서울시 자전거도로 현황(2013년 이후) 통계


서울시 통계정보시스템에서 제공하는 자전거도로 현황에 대한 통계정보입니다.서울시 소재 자전거도...

수정일자: 2025-04-07 제공기관: 서울특별시 제공부서: 디지털도시국 데이터전략과

[교통]

SHEET CHART

통계



	지역별(1)	지역별(2)	도로별(1)	도로별(2)	2012	2012.1
0	지역별(1)	지역별(2)	도로별(1)	도로별(2)	노선수 (개)	길이 (km)
1	합계	소계	계	소계	421	666.0
2	합계	소계	계	자전거전용도로	72	175.6
3	합계	소계	계	자전거보행자겸용도로	307	435.0
4	합계	소계	계	자전거전용차로	42	55.4
...	...	...	...	...	...	...
91	합계	지천	계	자전거보행자겸용도로	44	123.3
92	합계	여의도공원	계	소계	-	2.9
93	합계	여의도공원	계	자전거전용도로	-	2.9
94	합계	월드컵공원	계	소계	-	5.9
95	합계	월드컵공원	계	자전거전용도로	-	5.9

96 rows × 6 columns

데이터 수집 (기상)

- 즉각적 수요 반응: 강수.강설.폭염 시 이용량 급감 또는 급증 패턴 포착
- 계절성 반영: 월별.시간대별 온도.습도 패턴을 외생 변수로 활용 배치
- 최적화 근거: 악천후 대비 PM 수요 예측.배치량 증감 의사결정 지원

파일셋

OPEN-API

검색조건

기간

2025년 06월 ~ 2025년 06월

전체

서울특별시

부산광역시

대구광역시

인천광역시

광주광역시

대전광역시

울산광역시

세종특별자치시

경기도

강원특별자치도

충청북도

충청남도

전체

요소

강수형태

습도

강수

하늘상태


기온

뇌전

풍향

풍속

> 조회



습도				풍속			
<pre>location_hum = pd.read_csv(r'C:\Users\du596\Desktop\프로젝트\24년도\중량구\전북분류\풍속_202401_202412.csv', encoding='cp949')</pre>				<pre>location_wind = pd.read_csv(r'C:\Users\du596\Desktop\프로젝트\24년도\중량구\전북분류\풍속_202401_202412.csv', encoding='cp949') location_wind.columns = ['날', '시간', '풍속']</pre>			
연도	월	날	시간	강수	기온	습도	풍속
2021	1	1	0	0	-2.5	50	0.9
2021	1	1	1	0	-0.3	47	1.2
2021	1	1	2	0	0.8	49	1.1
2021	1	1	3	0	1.8	51	1.2
2021	1	1	4	0	1.7	50	1.3
2021	1	1	5	0	0.8	54	1.4
2021	1	1	6	0	0.1	58	1.2
2021	1	1	7	0	-0.2	62	1.1
2021	1	1	8	0	-0.8	68	1.2
2021	1	1	9	0	-1.6	78	1.1
2021	1	1	10	0	-1.7	80	1.2
2021	1	1	11	0	-1.4	74	0.8
2021	1	1	12	0	-1.3	56	2
2021	1	1	13	0	-2.1	48	2.5
2021	1	1	14	0	-3	47	2.3
2021	1	1	15	0	-3.9	32	1
2021	1	1	16	0	-4.4	33	1.6
2021	1	1	17	0	-5.2	34	1.4
2021	1	1	18	0	-5.8	38	1.4
2021	1	1	19	0	-6.3	35	0.6
2021	1	1	20	0	-6.7	34	0.9
2021	1	1	21	0	-7.1	33	1.1
2021	1	1	22	0	-7.3	34	0.9
2021	1	1	23	0	-5.6	29	0.9
2021	1	2	0	0	-4.2	30	1.7

```
location_rain = location_rain[['월', '날', '시간', '강수']]

# 시간 단위
location_rain['시간'] = pd.to_numeric(location_rain['시간'], errors='coerce') // 100

# csv 파일
#location_rain.to_csv('중량구_강수_전북분류.csv', index=False, encoding='utf-8-sig')
#location_rain.to_csv(r'C:\Users\du596\Desktop\프로젝트\중량구_강수_전북분류.csv', index=False, encoding='utf-8-sig')
```


```
# 풍속 단위
location_temp = location_temp[['월', '날', '시간', '기온']]

# 시간 단위
location_temp['시간'] = pd.to_numeric(location_temp['시간'], errors='coerce') // 100


# csv 파일
#location_temp.to_csv('중량구_기온_전북분류.csv', index=False, encoding='utf-8-sig')
#location_temp.to_csv(r'C:\Users\du596\Desktop\프로젝트\중량구_기온_전북분류.csv', index=False, encoding='utf-8-sig')
```

데이터 분석(인구데이터 기반)

total_population
왜도=1.416, 첨도=3.311




생활인구수와대여량의상관관계




- 생활인구수와 대여량 사이에 양(+)의 상관관계 존재
- 일정 인구수 이상부터 대여량이 급격히 증가
- 인구 밀집 지역을 중심으로 수요 예측 가능

데이터 분석(인프라데이터 기반)




노선길이에 따른 평균 대여량:
단순한 길이보다 실효성 높은 노선 선호경향



행정구별 대여량 분포 :
교통요지 및 주거 밀집 지역의 수요 급증

데이터 분석(기후데이터 기반)




기온

- PM 대여는 15~25도에서 가장 활발하게 나타나며, 극한 기온에서는 급감하는 경향이 뚜렷함.

습도

- PM 대여는 맑고 따뜻하며, 습도와 바람이 적절한 날씨에서 집중됨.
- 기상 악조건(비, 강풍, 극한온도)은 PM 대여를 억제하는 핵심 요소임.




강수

- 비가 오지 않는 날에만 대여가 활발하며, 강수 여부 자체가 PM 대여의 주요 제한 요인으로 작용.

풍속

- 약한 바람(0~2m/s)일 때 대여가 집중되며, 강풍(4m/s 이상) 시 대여가 급감하는 경향이 확인됨.

시계열 분석



일간 주기성


Prophet 모델을 활용한 시계열 분석 결과, 서울시 PM 대여량은 뚜렷한 일간, 주간, 계절 주기성을 보이며, 특히 출퇴근 시간대와 주말에 특징적인 패턴이 발견됨

데이터 분석을 통해 신속/정확한 실시간 수요대응 예측모델 개발의 토대가 됨

정확히 구분되며,
이 확인됨

계절 주기성

계절 분석 결과, 봄(4-5월)과 가을(9-10월)에 이용률이 가장 높고, 여름 폭염기와 겨울 한파기에는 이용률이 크게 감소하는 계절적 변동성이 뚜렷함



목차

01 프로젝트 개요

- 문제 배경
- 웹서비스 시연

02 데이터 수집 및 분석

- 데이터 수집 개요
- 데이터 분석 인사이트
- 시계열 특성


03 모델개발과정

- M1 모델
- M2 모델

04 발전계획


- 향후추진계획
- 참고문헌
- Q&A

모델 설계 가설 설정




M1 : 공공자전거 수요 예측 모델 + M2 모델(PM 수요 예측) Feature 활용

Classification





M2 모델의 Feature로서 더 적합한 방식은 무엇인가?
=> 공공자전거의 이상치, 불균형 분포 데이터 특성





Test Accuracy: 0.9919
Test Classification Report

	precision	recall	f1-score	support
0	1.000	1.000	1.000	17234
1	1.000	1.000	1.000	22556
2	1.000	1.000	1.000	25254
3	0.986	0.985	0.985	25205
4	0.985	0.986	0.985	25151
5	0.995	0.986	0.991	24106
6	0.983	0.987	0.985	25259
7	0.984	0.993	0.988	25507
8	0.997	0.994	0.995	28642
accuracy			0.992	218914
macro avg	0.992	0.992	0.992	218914
weighted avg	0.992	0.992	0.992	218914

Linear Regression





M1 모델 선정




LightGBM Classification

	precision	recall	f1-score	support
0	1.000	1.000	1.000	17234
1	1.000	1.000	1.000	22556
2	1.000	1.000	1.000	25254
3	0.986	0.985	0.985	25205
4	0.985	0.986	0.985	25151
5	0.995	0.986	0.991	24106
6	0.983	0.987	0.985	25259
7	0.984	0.993	0.988	25507
8	0.997	0.994	0.995	28642
accuracy			0.992	218914
macro avg	0.992	0.992	0.992	218914
weighted avg	0.992	0.992	0.992	218914



유형	모델명	목적	최종 성능 지표	주요 특성	장단점
분류분석모델	LSTM Classification	순차/시계열 분류	Accuracy: 99%, F1: 0.99	LSTM 계층 + Dense 구조	✓ 시계열에 강함 ✗ 느린 학습, 과적합 주의
	DNN Classification	일반 범주 분류	Accuracy: 97%, F1: 0.97	다층 퍼셉트론 기반 단순 분류	✓ 빠른 학습 ✗ 시계열 정보 반영 어려움
	LightGBM Classification	트리 기반 범주 분류	Accuracy: 99.19%, F1: 0.992	비신경망 트리 모델, 빠름	✓ 고성능 + 해석 가능 ✗ 시계열에는 비직관적
선형회귀모델	LSTM Linear Regression	시계열 수치 예측	Loss: 14.979MAE: 2.0	LSTM + Dense, 수치 예측 목적	✓ 시계열 예측에 강함 ✗ 예측 오차 다소 큼
	DNN Linear Regression	일반 수치 예측	Loss: 0.289MAE: 0.32	Dense 기반 회귀	✓ 간결 + 정밀 예측 ✓ 시계열 속성 1년전 데이터 해소

M1 모델 선정 DNN Linear Regression



모델 구조

- 입력층: 시간, 위치, 기상 특성
- 은닉층: 3개 (256, 128, 64 유닛)
- 활성화 함수: ReLU
- 출력층: Linear (회귀 출력)







성능 평가

- MAE: 0.32
- RMSE: 0.41
- R^2 : 0.87


DNN Linear Regression

1. 프로젝트 적합성 : 타겟 변수의 특이성 고려
2. 실용적 정확도 : LSTM 회귀 보다 MAE가 1/6 수준
3. 확장성 : 모델구조 단순함.


M1 모델: Feature 상관관계 분석




M1 모델: Feature 상관관계 분석



노선 길이 증가가 대여량 증가의 필수 조건이 아니라 충분 조건




M1 모델: Feature 시계열 특성 점검



시간의 변화에 따른 대여량 변화 추이

- 7월을 기준으로 비슷한 파동형태 그래프 주기성 점검

*검정색 선 : 각 연도의 7월을 의미




Prophet을 통한 시간 주기성 체크

- 표준편차의 폭이 커 Prophet만으로 예측은 제한됨을 확인함.


*하늘색 파동 외곽선 : Prophet 모델의 편차 표현과 forecast 주기성을 확인할 수 있음

M1 모델 : 데이터 분포 확인



입력변수 데이터 시각화 후 분포확인

- 입력변수의 분포가 대다수 "비정규성", "극단값", "불균형 분포"
- * 스케일 조정을 통해 입력변수의 변동성을 해소




Dataprep을 통한 타겟 변수 체크


- 데이터의 75%가 232 이하 -> 대다수 서비스는 저수요 구간
- 필요시 MinMaxScaler 또는 RobustScaler를 사용하여 이상치 예측 가능한 모델구현 필요

M1 모델: 타겟 변수 분포 확인


대여량 분포 분석






대여량 분포 분석




대여량 분포 (왜도 및 첨도 시각화)



타겟 변수의 비정규성과 이상치 확인
=> 범주 선정에 주의



M1 모델: 데이터 분포 확인



최초 균등 분배 범주

```
def class_to_range(pred_class):  
    # qcut 구간을 이용해서 문자로 반환  
    bins = [1, 19, 37, 62, 93, 131, 180, 254, 393, 3258]  
    pred_class = int(pred_class)  
    left = int(bins[pred_class])  
    right = int(bins[pred_class+1]) if pred_class+1 < len(bins) else 'max'
```

M1 model : Classification => Linear Regression 설계 변경?

```
# 범주형 구간 자동(9개) 생성 (qcut 사용) => 데이터 쓸림이 없도록 구간을 자동 생성  
num_bins = 9  
df['대여량_class'], bins = pd.qcut(df['대여량'], q=num_bins, labels=False, retbins=True, duplicates='drop')  
print("대여량 구간 경계값:", bins)
```

대여량 구간 경계값: [1.000e+00 1.900e+01 3.700e+01 6.200e+01 9.300e+01 1.310e+02 1.800e+02
2.540e+02 3.930e+02 3.258e+03]

Class 0 : 1 ~ 19
Class 6 : 181 ~ 254
Class 7 : 255 ~ 393
Class 8 : 394 ~ 3258(max)

분류분석 모델 결과

LSTM_Classification

DNN_Classification

LightGBM_Classification

모델구조

Layer (type)	Output Shape	Param #
lstm_4 (LSTM)	(None, 128)	72704
dense_8 (Dense)	(None, 128)	16512
dropout_4 (Dropout)	(None, 128)	0
dense_9 (Dense)	(None, 9)	1161

=====


Total params: 90,377

Trainable params: 90,377


Non-trainable params: 0

=====

혼동행렬



학습그래프



성능지표

loss : 0.034
accuracy : 0.99 %
precision : 0.99
recall : 0.99
f1_score : 0.99

요약 :

1. 순차 데이터 분류에 유리
2. 일관된 예측 품질 확보
3. 신뢰도 높은 분류 결과 기대 가능

분류분석 모델 결과

LSTM_Classification


DNN_Classification

LightGBM_Classification


모델구조

Layer (type)	Output Shape	Param #
input_4 (InputLayer)	[(None, 13)]	0
dense_12 (Dense)	(None, 128)	1792
dense_13 (Dense)	(None, 512)	66048
dense_14 (Dense)	(None, 128)	65664
dense_15 (Dense)	(None, 9)	1161

혼동행렬



학습그래프



성능지표

loss : 0.068
accuracy : 0.97 %
precision : 0.97
recall : 0.97
f1_score : 0.97

요약 :

1. 일반구조 데이터 분류에 유리
2. 일관된 예측 품질 확보
3. 경량 구조로 높은 성능 확보

분류분석 모델 결과

LSTM_Classification


모델구조

Test Accuracy: 0.9919

Test Classification Report

	precision	recall	f1-score	support
0	1.000	1.000	1.000	17234
1	1.000	1.000	1.000	22556
2	1.000	1.000	1.000	25254
3	0.986	0.986	0.986	25205


혼동행렬



DNN_Classification

어떤 분류분석 모델을 활용해도 M2 샘플모델에서 accuracy 40% 미만

accuracy			0.992	218914
macro avg	0.992	0.992	0.992	218914
weighted avg	0.992	0.992	0.992	218914




- 요약 :
- 1. 대규모 데이터 셋에 대해 높은 처리효율
 - 2. 클래스 간 균형 잡힌 성능
 - 3. 일반화 성능과 속도 측면에서 우수

선형회귀 모델 결과

LSTM_
Linear_Regression

DNN_Linear_Regression



최종성능지표


loss : 14.979

MAE : 2.0

1. 모델의 타겟 변수 전체에 대해선 성능이 우수하나
2. 저수요 구간에 대다수의 타겟 변수가 분포함에 따라 MAE가 높음

선형회귀 모델 결과

- LSTM_Linear_Regression
- DNN_Linear_Regression








최종성능지표

loss : 0.289
MAE : 0.32

1. 기존모델 대비 손실과 MAE 대폭감소
2. 정밀한 수치 예측이 필요한 회귀 문제에 적합
3. 학습 안정성과 성능이 균형있게 확보

M2 모델 선정



유형	모델명	목적	최종 성능 지표	주요 특성	장단점
분류분석모델	LSTM Classification	순차/시계열 분류	Accuracy: 76%, F1: 0.75	LSTM 계층 + Dense 구조	✓ 시계열에 강함 ✗ 느린 학습, 과적합 주의
	DNN Classification	일반 범주 분류	Accuracy: 74%, F1: 0.73	다층 퍼셉트론 기반 단순 분류	✓ 빠른 학습 ✗ 시계열 정보 반영 feature 추가
	LightGBM Classification	Boosting 기반 범주 분류	Accuracy: 78%, F1: 0.8	비신경망 트리 모델, 빠름	✓ 고성능 + 해석 가능 ✗ 시계열에는 비직관적
	CatBoost Classification	Boosting 기반 범주 분류	Accuracy: 75%, F1: 0.76	Gradient Boosting 기반 앙상블 모델, recall에 강점	✓ 고성능 + 해석 가능 ✗ 시계열에는 비직관적
	RandomForest Classification	Bagging 기반 앙상블 모델	Accuracy: 84%, F1: 0.85	배깅(Bagging) 기반 앙상블 모델	✓ 과적합 제어력 ✗ 시계열 정보 반영 feature 추가

M2 모델 선정 RandomForest

RandomForest



모델 구조

- n_estimators = 3000
- max_depth = 15
- class_weight = 'balanced'


성능 평가

- Accuracy : 84%
- Precision : 88%
- Recall : 84%
- F1_score : 85%

RandomForest


1. 타 모델 대비 월등한 성능
2. 예측 목표로 삼았던 공급 부족과 공급 절대 부족 범주에 대한 recall 우수

M2 모델: 민간 PM 수요예측모델



도메인 분석

- 예측 대상: 민간 PM 대여 수요
- 영향 요인: 일시, 행정구, 생활 인구수, 강수, 습도, 기온, 풍속, 공공자전거 대여량 등
- 공공자전거와 유사한 사용 패턴 예상




시계열 속성을 고려한 모델설정

- 선정 모델: RandomForest
 - 다범주 타겟(공급과다~공급절대부족) 중 공급부족·공급절대부족 예측 정확도가 가장 높음
- 의의: PM을 효율적으로 재배치하여 수익 극대화 달성

M2 모델: Feature 분석


샘플모델 결과

- 사용 데이터: 2022년 1월 ~ 3월
- 분류모델 정확도: 약 70~75%
- 정확도 75% 이상을 달성하기 위해 Feature 간 상관관계 및 중요도 분석 수행



상관관계 분석


- 대부분 feature 간 상관관계수는 낮은 편으로 분석됨.
- 상관관계 낮은 feature는 별도로 중요도 확인 필요



Feature Importance

- 중요도 값이 0에 수렴하는 feature는 제거 후 모델 학습 고려
- 전체 그래프가 점진적으로 증가
→ feature의 다양성 부족 및 추가 데이터 확보의 한계 시사
- 필요시 토지 활용도, 건축 목적 등 추가 데이터 확보필요


M2 모델: Feature 시계열 특성 점검



시간의 변화에 따른 대여량 변화 추이

-7월을 기준으로 비슷한 파동형태 그래프 주기성 점검

*검정색 선 : 각 연도의 7월을 의미




Prophet을 통한 시간 주기성 체크

- 표준편차의 폭이 커 Prophet만으로 예측은 제한됨을 확인함.


*하늘색 파동 외곽선 : Prophet 모델의 편차 표현과 forecast 주기성을 확인할 수 있음

M2 모델 타겟변수 범주설정



KMeans 분석

- KMeans 클러스터링을 통해 민간 PM 수요 패턴 분석
 - 유사한 수요 특성을 가진 지역 그룹화
 - 시간대별 수요 변동성 파악
- 클러스터 중심점 기반 수요 특성 도출



수동 Binning 분류

- 5개 클래스로 수요 등급 세분화
- 각 클래스별 특성 및 분포 분석
- 재배치 우선순위 결정에 활용

M2 모델: 민간 PM (2)

타겟변수 최대값 : 167
타겟변수 최소값 : 3
타겟변수 평균 : 28.435073610833772
타겟변수 표준편차 : 24.659611717346884
count 550870.000000
mean 28.435074
std 24.659612
min 3.000000
25% 9.000000
50% 22.000000
75% 39.000000
max 167.000000

통계적 특성

- 평균: 28 / 최대값: 167 / 표준편차: 24
- 비대칭 분포 + 이상치 존재

25개
단위

클러스터수 : 2, 실루엣 계수 : 0.5034152029287449
클러스터수 : 3, 실루엣 계수 : 0.35829080766409677
클러스터수 : 4, 실루엣 계수 : 0.2928090306335364
클러스터수 : 5, 실루엣 계수 : 0.25021259315453737
클러스터수 : 6, 실루엣 계수 : 0.24037891458352895
클러스터수 : 7, 실루엣 계수 : 0.23465306470953057
클러스터수 : 8, 실루엣 계수 : 0.2252786575537092
클러스터수 : 9, 실루엣 계수 : 0.21832308531956343

1개월
단위

클러스터수 : 2, 실루엣 계수 : 0.50380245956795
클러스터수 : 3, 실루엣 계수 : 0.3571750579350531
클러스터수 : 4, 실루엣 계수 : 0.31127190214918143
클러스터수 : 5, 실루엣 계수 : 0.2703939030900694
클러스터수 : 6, 실루엣 계수 : 0.27035878459618323
클러스터수 : 7, 실루엣 계수 : 0.26017600961164794
클러스터수 : 8, 실루엣 계수 : 0.25187154305100445
클러스터수 : 9, 실루엣 계수 : 0.244388411222825


1년
단위

클러스터수 : 2, 실루엣 계수 : 0.5020230718545858
클러스터수 : 3, 실루엣 계수 : 0.3587312000312493
클러스터수 : 4, 실루엣 계수 : 0.3121305262017013
클러스터수 : 5, 실루엣 계수 : 0.2713132441876673
클러스터수 : 6, 실루엣 계수 : 0.2714484744987242
클러스터수 : 7, 실루엣 계수 : 0.2613360692833384
클러스터수 : 8, 실루엣 계수 : 0.2532321690074345
클러스터수 : 9, 실루엣 계수 : 0.2457243502992503

샘플링 데이터 체크

- KMeans + 실루엣 계수 분석
→ 클러스터 수 2개가 가장 양호
- 메모리 한계로 시계 단위 별도 샘플링 적용

대여량 클래스별 샘플수 (qcut)




타겟변수 범주화


- 자동 군집 결과는 PM 수요 판단에 미흡
- 데이터 불균형은 있으나 학습에 필요한 수준은 충족됨

M2 모델: 민간 PM (2)


대여량 분포 분석






대여량 분포 분석



대여량 분포 (왜도 및 첨도 시각화)



타겟 변수의 비대칭 분포 와 이상치 확인



M2 모델: 민간 PM (2)

타겟변수 최대값 : 167
 타겟변수 최소값 : 3
 타겟변수 평균 : 28.435073610833772
 타겟변수 표준편차 : 24.659611717346884
 count 550870.000000
 mean 28.435074
 std 24.659612
 min 3.000000
 25% 9.000000
 50% 22.000000
 75% 39.000000
 max 167.000000


통계적 특성

- 평균: 28 / 최대값: 167 / 표준편차: 24
- 비대칭 분포 + 이상치 존재

25개 단위	클러스터수 : 2, 실루엣 계수 : 0.5034152029287449
	클러스터수 : 3, 실루엣 계수 : 0.35829080766409677
	클러스터수 : 4, 실루엣 계수 : 0.2928090306335364
	클러스터수 : 5, 실루엣 계수 : 0.25021259315453737
	클러스터수 : 6, 실루엣 계수 : 0.24037891458352895
	클러스터수 : 7, 실루엣 계수 : 0.23465306470953057
	클러스터수 : 8, 실루엣 계수 : 0.2252786575537092
	클러스터수 : 9, 실루엣 계수 : 0.21832308531956343
1개월 단위	클러스터수 : 2, 실루엣 계수 : 0.50380245956795
	클러스터수 : 3, 실루엣 계수 : 0.3571750579350531
	클러스터수 : 4, 실루엣 계수 : 0.31127190214918143
	클러스터수 : 5, 실루엣 계수 : 0.2703939030900694
	클러스터수 : 6, 실루엣 계수 : 0.27035878459618323
	클러스터수 : 7, 실루엣 계수 : 0.26017600961164794
	클러스터수 : 8, 실루엣 계수 : 0.25187154305100445
	클러스터수 : 9, 실루엣 계수 : 0.244388411222825
1년 단위	클러스터수 : 2, 실루엣 계수 : 0.5020230718545858
	클러스터수 : 3, 실루엣 계수 : 0.3587312000312493
	클러스터수 : 4, 실루엣 계수 : 0.3121305262017013
	클러스터수 : 5, 실루엣 계수 : 0.2713132441876673
	클러스터수 : 6, 실루엣 계수 : 0.2714484744987242
	클러스터수 : 7, 실루엣 계수 : 0.2613360692833384
	클러스터수 : 8, 실루엣 계수 : 0.2532321690074345
	클러스터수 : 9, 실루엣 계수 : 0.2457243502992503

샘플링 데이터 체크


- KMeans + 실루엣 계수 분석
→ 클러스터 수 2개가 가장 양호
- 메모리 한계로 시계 단위 별도 샘플링 적용



타겟변수 범주화


- 자동 군집 결과는 PM 수요 판단에 미흡
- 데이터 불균형은 있으나 학습에 필요한 수준은 충족됨

M2 모델 타겟변수 범주설정



KMeans 분석

- KMeans 클러스터링을 통해 민간 PM 수요 패턴 분석
 - 유사한 수요 특성을 가진 지역 그룹화
 - 시간대별 수요 변동성 파악
- 클러스터 중심점 기반 수요 특성 도출



수동 Binning 분류

- 5개 클래스로 수요 등급 세분화
- 각 클래스별 특성 및 분포 분석
- 재배치 우선순위 결정에 활용

M2 모델: 민간 PM (2)

타겟변수 최대값 : 167
타겟변수 최소값 : 3
타겟변수 평균 : 28.435073610833772
타겟변수 표준편차 : 24.659611717346884
count 550870.000000
mean 28.435074
std 24.659612
min 3.000000
25% 9.000000
50% 22.000000
75% 39.000000
max 167.000000


통계적 특성

- 평균: 28 / 최대값: 167 / 표준편차: 24
- 비대칭 분포 + 이상치 존재

25개 단위	클러스터수 : 2, 실루엣 계수 : 0.5034152029287449
	클러스터수 : 3, 실루엣 계수 : 0.35829080766409677
	클러스터수 : 4, 실루엣 계수 : 0.2928090306335364
	클러스터수 : 5, 실루엣 계수 : 0.25021259315453737
	클러스터수 : 6, 실루엣 계수 : 0.24037891458352895
	클러스터수 : 7, 실루엣 계수 : 0.23465306470953057
	클러스터수 : 8, 실루엣 계수 : 0.2252786575537092
	클러스터수 : 9, 실루엣 계수 : 0.21832308531956343
1개월 단위	클러스터수 : 2, 실루엣 계수 : 0.50380245956795
	클러스터수 : 3, 실루엣 계수 : 0.3571750579350531
	클러스터수 : 4, 실루엣 계수 : 0.31127190214918143
	클러스터수 : 5, 실루엣 계수 : 0.2703939030900694
	클러스터수 : 6, 실루엣 계수 : 0.27035878459618323
	클러스터수 : 7, 실루엣 계수 : 0.26017600961164794
	클러스터수 : 8, 실루엣 계수 : 0.25187154305100445
	클러스터수 : 9, 실루엣 계수 : 0.244388411222825
1년 단위	클러스터수 : 2, 실루엣 계수 : 0.5020230718545858
	클러스터수 : 3, 실루엣 계수 : 0.3587312000312493
	클러스터수 : 4, 실루엣 계수 : 0.3121305262017013
	클러스터수 : 5, 실루엣 계수 : 0.2713132441876673
	클러스터수 : 6, 실루엣 계수 : 0.2714484744987242
	클러스터수 : 7, 실루엣 계수 : 0.2613360692833384
	클러스터수 : 8, 실루엣 계수 : 0.2532321690074345
	클러스터수 : 9, 실루엣 계수 : 0.2457243502992503

샘플링 데이터 체크

- KMeans + 실루엣 계수 분석
→ 클러스터 수 2개가 가장 양호
- 메모리 한계로 시계 단위 별도 샘플링 적용




타겟변수 범주화

- 자동 군집 결과는 PM 수요 판단에 미흡
- 데이터 불균형은 있으나 절대적인 데이터의 양이 충분하다고 판단, 학습

딥러닝 분류분석 모델 결과

DNN_Classification

LSTM_Classification



성능지표


loss : 0.584
accuracy : 0.74 %
precision : 0.74 %
recall : 0.74 %
f1_score : 0.73 %

- 요약 :
- 1. 목표 accuracy 도달 X
 - 2. 공급부족 recall 30.99%
 - 3. 공급절대부족 recall 8.23%

딥러닝 분류분석 모델 결과

DNN_Classification

LSTM_Classification



성능지표

loss : 0.584
accuracy : 0.74 %
precision : 0.74 %
recall : 0.74 %
f1_score : 0.73 %


요약 :

- 1. 목표 accuracy 도달 X
- 2. 공급부족 recall 30.99%
- 3. 공급절대부족 recall 8.23%

딥러닝 분류분석 모델 결과

DNN_Classification

LSTM_Classification



성능지표

loss : 0.579
accuracy : 0.76 %
precision : 0.76 %
recall : 0.76 %
f1_score : 0.75 %

- 요약 :
- 1. 목표 accuracy 도달(76%)
 - 2. 공급부족 recall 33.77%
 - 3. 공급절대부족 recall 30.63%


딥러닝 분류분석 모델 결과

DNN_Classification



성능지표
loss : 0.579
accuracy : 0.76 %

- LightGBM : 빠른 학습 속도와 다양한 시계열 feature를 활용한 패턴 학습에 강한 부스팅 모델
 - CatBoost : 범주형 변수 처리에 특화되어 불균형 데이터에 강한 부스팅 모델
- RandomForest : 비선형성과 갑작스러운 변화를 잘 포착하는 트리 기반 앙상블 모델



- 요약 :
1. 목표 accuracy 도달(76%)
 2. 공급부족 recall 33.77%
 3. 공급절대부족 recall 30.63%

머신 러닝 모델 파라미터 탐색

sklearn.model_selection.GridSearchCV Parameter 탐색

- 샘플데이터(22년 3개월)를 통해 탐색 시도
- 여러 파라미터를 시도하여 최적의 파라미터를 체크 후 파라미터의 영역을 확장 탐색


```
GridSearchCV(cv=2, estimator=Pipeline(steps=[('lgbm', LGBMClassifier())]),  
             n_jobs=-1,  
             param_grid={'lgbm__learning_rate': [0.01, 0.05, 0.1],  
                         'lgbm__max_depth': [3, 5, 7, -1],  
                         'lgbm__n_estimators': [100, 300, 500],  
                         'lgbm__num_leaves': [15, 31, 63]},  
             verbose=2)
```

```
grid_search.best_params_
```

```
{'lgbm__learning_rate': 0.01,  
 'lgbm__max_depth': -1,  
 'lgbm__n_estimators': 3000,  
 'lgbm__num_leaves': 63}
```

탐색 결과 분석

- 최초 n_estimator = [100,200,300,1000,2000,3000]
- Boosting 마다 predict 값을 체크하여 accuracy의 변화 확인
- GridSearchCV를 통해 estimators의 값을 추가로 체크




머신러닝 분류분석 모델 결과

LGBM_Classification

CatBoost_Classification

RandomForest_Classification



성능지표

accuracy : 0.78 %
precision : 0.84 %
recall : 0.78 %
f1_score : 0.8 %


- 요약 :
- 1. 목표 accuracy 도달(78%)
 - 2. 공급부족 recall 78.93%
 - 3. 공급절대부족 recall 89.25%

머신러닝 분류분석 모델 결과

LGBM_Classification

CatBoost_Classification

RandomForest_Classification



성능지표

accuracy : 0.75 %
precision : 0.8 %
recall : 0.75 %
f1_score : 0.76 %

- 요약 :
- 1. 목표 accuracy 도달(75%)
 - 2. 공급부족 recall 69.89%
 - 3. 공급절대부족 recall 90.18%


머신러닝 분류분석 모델 결과

LGBM_Classification

CatBoost_Classification

혼동행렬


Confusion Matrix (Test Set)



성능지표

accuracy : 0.84 %
precision : 0.88 %
recall : 0.84 %



- 재배치가 필요한 지역을 가장 잘 예측하는 모델



요약 :

- 1. 목표 accuracy 도달(84%)
- 2. 공급부족 recall 87.98%
- 3. 공급절대부족 recall 89.51%

최종 모델 선정



M1: DNN 모델

- 공공자전거(따릉이) 수요 예측에 최적화
- 시계열 특성 반영 가능한 구조
- Linear Regression 레이어 활용
- 다양한 변수 간 복잡한 상호작용 학습 가능
- MAE = 0.32로 우수한 성능 달성
- 시간대별, 지역별 수요 패턴 정확히 포착
- 기상 조건과 유동인구 데이터 효과적 활용
- 실시간 데이터 처리에 적합

M2: RandomForest 모델

- 민간 PM 수요 등급 분류에 최적화
- 공급 부족 87.98%, 공급 절대 부족 89.51% 등 높은 성능과 Recall_score
- 과적합 위험이 낮아 안정적 예측 가능
- 특성 중요도 분석으로 주요 변수 파악 용이
- 비선형적 관계 포착 능력 우수
- 이상치에 강건한 성능 보장
- 해석 가능성과 예측 정확도 균형 유지
- 다양한 환경 조건에서 일관된 성능 제공

목차

01 프로젝트 개요

- 문제 배경
- 웹서비스 시연

02 데이터 수집 및 분석

- 데이터 수집 개요
- 데이터 분석 인사이트
- 시계열 특성

03 모델개발과정

- M1 모델
- M2 모델


04 발전계획

- 향후추진계획
- 참고문헌
- Q&A

향후 계획

주요 개선점

- **데이터 해상도 부족:**
행정구 단위의 해상도로 미세 분석 어려움
- **외부 변수 미반영:**
이벤트(집회, 공연 등) 데이터 부족
- **장기 데이터 부족:**
정성적 분석 한계
- **모델 구조적 한계:**
과적합 위험, 웹 서비스간 로딩시간 발생
- **복합 교통수단 모델링 어려움**



데이터 품질 개선

해상도 상향, 민간 정밀 데이터 공유,
실시간 외부 변수 연동

시스템 고도화

클라우드 기반 확장,
모바일 접근성 강화

실증 및 확장

파일럿 테스트
타 도시 확대 검토

참고문헌

시계열 분석	Facebook Prophet 시계열 예측 모델 논문 (2017)
머신러닝 모델	RandomForest 분류 알고리즘 연구 (Kim et al., 2022)
웹 개발	Flask 웹 프레임워크 공식 문서 (2023)
PM 관련 정책	서울시 공공자전거 운영 보고서 (2024)
데이터 분석	Python 데이터 분석 라이브러리 문서 (2023)

감사합니다

팀명: 기업맞춤형 AI-X
팀원: 조명환, 정선우, 정종혁, 김도현
문의: ai-x@example.com